

# VULNERABILIDADES EN LA IA MODERNA

Basado en el artículo [Understanding AI Vulnerabilities](#)

-Martínez Lizarraga Abel Alejandro

# INTRODUCCIÓN

ARTIFICIAL  
INTELLIGENCE  
(AI)

La IA moderna es poderosa, flexible y ampliamente utilizada.

Pero esta misma flexibilidad la hace vulnerable.

Nuevos tipos de ataques están apareciendo.

La seguridad en IA se vuelve cada vez más crítica



# ¿POR QUÉ LA IA ES VULNERABLE?



Mayor complejidad provoca mayor superficie de ataque




Modelos generativos pueden ser manipulados



Dependencia de datos masivos



Interacción mediante lenguaje natural



## IA TRADICIONAL

- Tareas específicas
- Clasificación y predicción
- Riesgo limitado

## IA GENERATIVA

- Produce contenido nuevo
- Interpreta lenguaje natural
- Más caminos para atacarla

# ARTIFICIAL INTELLIGENCE (AI)

## ADVERSARIAL ATTACKS

Cambios mínimos en el input provoca errores enormes en el output.

Pueden evadir filtros y engañar clasificadores.

- Usados para:
- Evadir detección
- Manipular decisiones
- Filtrar información

<<<



# DATA POISONING



SI LOS DATOS ESTÁN  
CONTAMINADOS



la IA aprende mal

- Respuestas sesgadas
- Fugas de información personal
- Comportamiento malicioso aprendido



RIESGOS



# ARTIFICIAL INTELLIGENCE (AI)

# PROMPT INJECTION


ART  
INTEL  
[AI]

Manipulación del modelo usando texto.

Permite:

- Saltar reglas
- Engañar políticas de seguridad
- Acceder a información privada
- Relacionado con ataques tipo jailbreak

<<<



# JAILBREAKING



TÉCNICAS PARA ROMPER LAS RESTRICCIONES  
DE SEGURIDAD DEL MODELO



PERMITE



- CONTENIDO PELIGROSO
- INSTRUCCIONES ILEGALES
- DATOS SENSIBLES
- AFECTA INCLUSO A MODELOS AVANZADOS

# ARTIFICIAL INTELLIGENCE (AI)

# VULNERABILIDADES EN APIs

ART  
INTE  
CAD

Las empresas usan modelos generativos vía API.  
Un error en el modelo puede provocar muchas empresas afectadas.

Riesgos:

- Exposición de clientes
- Ataques masivos
- Fugas de datos sensibles

<<<<



# SOLUCIONES



AI FIREWALL



SISTEMA QUE FILTRA INPUTS Y  
OUTPUTS



BLOQUEA




- PROMPTS MALICIOSOS
- CÓDIGO DAÑINO
- DATOS SENSIBLES
- FUNCIONA COMO UN FIREWALL TRADICIONAL,  
PERO PARA IA

# ARTIFICIAL INTELLIGENCE (AI)

# VALIDACIÓN DE DATOS



REVISIÓN PREVIA AL ENTRENAMIENTO



DETECTA



- SESGOS
- INFORMACIÓN PERSONAL
- CONTENIDO MALICIOSO
- EVITA FALLOS ÉTICOS Y FILTRACIONES



# ARTIFICIAL INTELLIGENCE (AI)

# ADVERSARIAL TESTING

Pentesting aplicado a modelos de IA.  
Simulan ataques reales.

- Permite identificar:
- Vulnerabilidades
- Comportamiento inesperado
- Fallos en outputs o instrucciones

<<<



# CASO REAL

## VULNERABILIDADES EN GUARDRAILS

Investigaciones recientes demostraron que incluso los sistemas de protección (guardrails) pueden ser evadidos

# NVIDIA FUE SOMETIDA A PRUEBAS ADVERSARIALES.

ARTI

INTEI

<<<

Los atacantes lograron usar prompts diseñados para:

- Saltar filtros de contenido
- Extraer datos privados del modelo
- Obtener instrucciones peligrosas sin autorización



nVIDIA®

## ¿CÓMO SE VULNERARON?

- Combinando instrucciones ambiguas con mensajes encadenados
- Alterando inputs de forma que parecían seguros pero contenían lógica oculta
- Aprovechando debilidades en la interpretación del lenguaje natural



RIESGOS ÉTICOS

# ARTIFICIAL INTeligencia

REPRODUCIR SESGOS

DISCRIMINAR


TOMAR DECISIONES  
INJUSTAS



# <<< REGULACIÓN Y RESPONSABILIDAD >>>

LAS EMPRESAS DEBEN IMPLEMENTAR


- GUARDRAILS
- IA SEGURA POR DISEÑO
- PROTECCIÓN DE DATOS
- REGULADORES EXIGEN TRANSPARENCIA  
Y SEGURIDAD



AL  
EN  
AI

## UN JUEGO DE GATO Y RATÓN

- No existe seguridad absoluta
- Cada nueva defensa genera un nuevo ataque
- La seguridad debe adaptarse constantemente



## CONCLUSIÓN

La IA moderna es extremadamente poderosa.  
Pero también es vulnerable a múltiples ataques.

La seguridad requiere:

- AI Firewalls
- Validación de datos
- Pruebas adversariales
- La protección será un proceso continuo

A  
IN  
CA  
AI

## ARTICULO

- [www.harvardmagazine.com/2025/03/artificial-intelligence-vulnerabilities-harvard-yaron-singer](http://www.harvardmagazine.com/2025/03/artificial-intelligence-vulnerabilities-harvard-yaron-singer)